

Литературный и рыночный обзор по ИИ-платформе для разработки методик ВЭЖХ-МС в биоаналитике

Краткий вывод

Идея выглядит **научно реализуемой и коммерчески осмысленной**, если формулировать ее не как «магическую универсальную модель для любого анализита и любой платформы», а как поэтапную систему: сначала — прогнозирование времени удерживания и ключевых метрик качества пика для ограниченного класса биоаналитических ВЭЖХ-МС/МС методов, затем — подбор оптимальных условий через оптимизатор поверх этих прогнозов, и только после этого — переход к более автономной разработке методики. Современная литература уже подтверждает четыре критически важные вещи: ретенцию можно предсказывать по структуре молекулы; модели можно переносить между хроматографическими методами и колонками; closed-loop оптимизация условий методом байесовской оптимизации и reinforcement learning работает; отдельные задачи МС-части, включая MRM-предсказание и оценку ионизационной эффективности, тоже уже автоматизируются. При этом сами обзоры по автоматизированной разработке методов подчеркивают, что полная автономность пока ограничена качеством молекулярных представлений, дизайном эксперимента и обработкой сигнала. ¹

Самое важное стратегическое уточнение такое: модель сможет обобщаться на **соединения, которых не было в обучении, если их химическая структура известна** и может быть представлена как SMILES, граф или набор дескрипторов; именно так работают современные transfer-learning, graph neural network и transformer-подходы. Но для вещества, которое химически не охарактеризовано, задача «подобрать методику» в полном объеме неразрешима, потому что входных признаков просто нет. Поэтому в бизнес-плане лучше формулировать обещание как «генерализация на новые для лаборатории соединения при известной структуре», а не как «работа с неизвестными веществами вообще». Это существенно сильнее и научнее. ²

Научная реализуемость модели

С точки зрения хроматографии замысел опирается на уже зрелое направление QSRR и более новые deep-learning подходы. Современные обзоры прямо указывают, что время удерживания зависит от **свойств анализита, подвижной фазы, неподвижной фазы, температуры и частично давления**, а значит задача естественным образом формулируется как supervised learning на смеси молекулярных и методических признаков. Для этого уже существуют и большие публичные наборы данных: METLIN SMRT содержит экспериментальные RP-LC retention times для 80 038 малых молекул, а RepoRT агрегирует 373 датасета, 8 809 уникальных соединений и 88 325 retention time entries, измеренных на 49 колонках при разных элюентах, расходах и температурах. Это не заменит 24 года внутренних данных вашей лаборатории, но показывает, что сама постановка задачи давно вышла из стадии «слишком смело для науки». ³

Дальше начинается самое интересное: литература уже ушла от моделей «одна колонка — одна модель». В работе 2024 года post-projection calibration дал медианную ошибку ниже 3,2% времени элюирования при переносе между разными chromatographic methods, а RT-Transformer был валидирован на SMRT и еще 41 датасете различных методов и смог отсеять 52,64% ложных кандидатов в задаче идентификации. В промышленном фарма-контексте графовые нейросети на внутреннем наборе из 7 552 молекул показали устойчивость к новым химическим сериям, а transfer-learning подходы специально разрабатывались как ответ на фрагментированность маломолекулярных retention datasets и ограниченность локальных обучающих выборок. Появились и исследования, где retention time моделируется сразу **в нескольких условиях** с учетом разных химий колонок и буферных условий как самостоятельного входного сигнала, а не как «шума метода». Для вашей задачи это означает, что прямая модель «вещество + условия → RT/качество пика» не только возможна, но и находится на переднем крае прикладной аналитической химии. ⁴

Самый сильный участок идеи — прогноз RT и связанной с ним временной логики анализа; более сложный участок — совместный прогноз **peak quality**. Тут литература заметно моложе, но уже не пустая. Есть работы, где ML предсказывает retention time, peak width и, через это, resolution; есть программные реализации, которые по SMILES и температуре предсказывают chromatographic parameters; есть отдельные исследования по explainable QC/evaluation extracted ion chromatograms и peak quality. Однако именно связка «RT + ширина + асимметрия/тэйлинг + S/N + разрешение до ближайшей матричной помехи + стабильность ответа в биоматрице» пока не выглядит решенной как единая универсальная задача для малых молекул в рутинном биоанализе. Отсюда ключевой вывод: **техническая реализуемость высокая для RT, средняя для peak-quality блока, и хорошая для обратной задачи, если решать ее через оптимизацию поверх суррогатных моделей, а не пытаться сразу учить одну end-to-end модель на все.** ⁵

Для МС-части картина похожая, но чуть менее зрелая именно в биоаналитическом, а не метаболомном смысле. Большие обзоры показывают, что ML в small-molecule mass spectrometry уже активно применяется для предсказания MS/MS-спектров, retention time и связанных физико-химических свойств. Есть отдельная линия работ по предсказанию ionization efficiency, включая active learning, и уже есть коммерчески оформленные примеры: AI Quantitation от SCIEX ⁶ в сотрудничестве с Mass Analytica ⁷ использует ML для MRM transition prediction, а в индустриальном кейсе на 5 757 соединениях сообщается, что при использовании предсказанных переходов были получены валидные stability/permeability данные для 97% соединений. Но здесь важно не переобещать: регуляторно значимая МС-часть в биоанализе очень чувствительна к матричным эффектам, ионизационному подавлению/усилению и лот-к-лот вариативности матрицы. Поэтому для практического MVP разумно разделить МС-задачу на подзадачи: выбор режима ионизации, ранжирование переходов, прогноз диапазона отклика, оценка риска матричного эффекта и только потом — тонкая оптимизация источника и collision energy. ⁸

Данные и архитектура решения

Главный актив проекта — не сама нейросеть, а **исторические данные лаборатории**, если их удастся превратить из архивов методик и хроматограмм в нормализованный обучающий массив. С практической точки зрения минимальная единица данных должна быть не «методика» и не «соединение», а **конкретное наблюдение analyte-method-run**. В него стоит включать структуру вещества и/или SMILES, вычисляемые молекулярные дескрипторы, колонку не только как бренд, но и как дескрипторы селективности, состав и pH подвижной фазы, градиент как временной профиль, температуру, расход, объем инъекции, тип матрицы и пробоподготовки, настройки источника и переходов, а на выходе — RT, peak width, S/N, tailing/asymmetry, plate count, resolution

до ближайшей мешающей зоны, интенсивность/area response и служебные QC-флаги. Такой дизайн данных соответствует тому, как современная литература трактует факторы retention и separation quality, и именно он позволит действительно обучать прямую модель, а не «угадывать по названию методики».

9

Архитектурно я бы рекомендовал не одну модель, а **слоистую систему суррогатов**. Первый слой — molecular representation: граф молекулы, SMILES-эмбединги и классические дескрипторы вроде lipophilicity, pKa, H-bonding и т.п. Второй слой — forward models: отдельная модель для RT с uncertainty estimation, отдельная — для формы/качества пика, отдельная — для response/MS-поведения. Третий слой — optimizer, который решает обратную задачу: ищет набор условий, максимизируя функцию качества, где одновременно учитываются resolution, runtime, S/N, tailing и, возможно, стоимость метода. Такой подход напрямую поддерживается литературой по automated method development: байесовская оптимизация уже показала способность находить хорошие градиентные решения менее чем за 35 измерений; сравнительные исследования показывают ее высокую data efficiency для search-based optimization; reinforcement learning начинает выигрывать на более многопараметрических задачах; а успех всего контура сильно зависит от правильно выбранной chromatographic response function.

10

Критически важно, чтобы первичная версия строилась **на узком, хорошо контролируемом домене**, а не на всех данных компании сразу. Литература по retention prediction repeatedly показывает, что публичные маломолекулярные данные фрагментированы по методам, а transfer learning нужен именно потому, что «одной общей таблицы на все случаи жизни» обычно нет. Поэтому разумный старт — один тип биоматрицы, одна-две instrument families, один dominant assay style, например RP-LC-MS/MS для малых молекул с ограниченным набором колонок и стандартных добавок. В таком срезе даже сравнительно простые модели могут работать хорошо: в ограниченных химических доменах по-code и descriptor-based подходы уже показывали высокую точность, а графовые модели — промышленную устойчивость к новым химическим сериям. Это снижает риск и одновременно создает быстрый демонстрационный кейс для руководства.

11

Регуляторные и методологические риски

Поскольку речь идет о биоаналитике для исследований биоэквивалентности, проект с самого начала должен считаться **ГХР-чувствительным**, даже если на первом этапе он будет использоваться только как внутренняя система поддержки решений. И FDA¹², и EMA¹³ через гармонизированную рамку ICH¹⁴ M10 требуют, чтобы биоаналитический метод был пригоден для intended purpose, валидирован и хорошо документирован. Для LC/MS-методов отдельно подчеркивается необходимость оценки matrix effect, включая разные lot/source матрицы. Для системных критериев качества хроматографической части USP¹⁵ рассматривает system suitability как интегральную часть процедуры, а связанные параметры — resolution, plate count, tailing factor, signal-to-noise и другие показатели формы пика — остаются центральными для фармацевтического анализа.

16

Из этого следует не только необходимость хороших метрик, но и другая, менее очевидная вещь: ваша модель должна быть **аудируемой**. Электронные записи и подписи попадают в рамку Part 11, если используются в регулируемом контуре, а международные data-integrity guidance ожидают риск-ориентированный review audit trails и метаданных. Это означает, что для промышленного внедрения понадобятся версия модели, версия обучающего датасета, журнал переобучений, воспроизводимость inference, фиксация ручных override аналитика, а лучше еще и объяснение, почему система предложила именно эти условия. Практически это сильный

аргумент в пользу формата «AI-copilot для аналитика», а не «черный ящик сам утверждает метод».

17

Главные методологические риски лежат в данных. Во-первых, у 24-летнего архива почти наверняка будет сильная гетерогенность: разные колонки, приборы, CDS, алгоритмы интеграции и naming conventions. Во-вторых, даже сами peak labels могут быть шумными: коммерческие CDS прямо показывают, насколько чувствительна интеграция к выбору peak width, slope sensitivity, специальных регионов и timed events. В-третьих, исторические базы часто хорошо хранят «финальные удачные методы», но плохо сохраняют неудачные scouting runs, а для обратной задачи именно неудачные эксперименты формируют поверхность отклика и учат модель, какие условия **не** работают. Поэтому первый этап в бизнес-плане — обработка массива, нормализация справочников и разметка — у вас сформулирован абсолютно правильно; без него проект будет не AI-продуктом, а красивой демонстрацией на грязных данных. 18

Рынок и конкурентная среда

Спрос на цифровое ускорение method development уже доказан рынком. У Waters Corporation 19 есть Empower Method Development Tools, которые позиционируются как средство сократить разработку и валидацию метода «с месяцев до недель», автоматически запускать эксперименты и работать в рамках traceability/compliance-ready workflows. Agilent Technologies 20 продвигает OpenLab CDS как CDS с интегрированными средствами method development и техническими контролями для Part 11, Annex 11 и других compliance frameworks. Thermo Fisher Scientific 21 предлагает Chromeleon с fully automated method development через ChromSword Connect. Shimadzu Corporation 22 продает LabSolutions MD с AQbD-подходом, predicted chromatogram и AI-алгоритмом автоматической оптимизации градиента. ACD/Labs 23 предлагает Method Selection Suite и AutoChrom для рекомендаций по pH/temperature/solvent/column selection, симуляции хроматограмм и direct instrument control. Отдельно существует зрелый класс специализированных пакетов вроде DryLab и ChromSword, а в MC-части уже появились решения типа AI Quantitation от SCIEX/Mass Analytica. Иными словами, рынок не требует доказательства потребности — он уже платит за инструменты, которые сокращают методическую разработку и уменьшают зависимость от чистой «насмотренности» аналитика. 24

Но из опубликованных описаний видно и окно возможности. Большинство нынешних промышленных продуктов сосредоточены на DoE, simulated chromatograms, AQbD, построении локальных моделей по нескольким input experiments и автоматизации workflow вокруг прибора. Это очень ценно, но это **не то же самое**, что lab-specific модель, обученная на многолетнем историческом архиве биоаналитической лаборатории и способная решать обе задачи пользователя: прямое предсказание качества хроматограммы по структуре и условиям и обратный поиск условий под заданные peak criteria. В MC-части тоже видна цель: AI Quantitation уже автоматизирует quantitation и MRM prediction, но это не полноценный structure-to-method engine для bioequivalence LC-MS/MS разработки. Поэтому ваш потенциальный дифференциатор — не «мы тоже делаем DoE», а «мы превращаем накопленную лабораторную историю в предиктивную систему, которая знает именно этот тип матриц, приборов, колонок и аналитических решений». Это уже заметно ближе к defensible moat. 25

По размеру рынка оценки расходятся из-за разной ширины определения категории, но все сценарии указывают на **многомиллиардный** адресуемый контур. Отчеты по HPLC оценивают мировой рынок примерно в 5,25–5,44 млрд долларов в 2025 году; liquid-platform chromatography instrumentation — в 5,69 млрд долларов; более широкие оценки chromatography instrumentation дают около 11,37 млрд долларов в 2025 году. Параллельно bioanalytical testing services

оцениваются примерно в 5,27 млрд долларов в 2025 году, а bioanalytical testing services in CRO — в 3,35 млрд долларов в 2024 году с дальнейшим ростом; отдельные оценки для BE studies выводят рынок к 1,27 млрд долларов к 2030 году. Для старта это означает, что самый реалистичный beachhead — не «все лаборатории вообще», а биоаналитические CRO, BE-лабы, generic pharma и DMPK/ADME-группы, где много повторяющейся targeted LC-MS/MS разработки и боль от ручного optimization bottleneck особенно ощутима. ²⁶

Экономическая целесообразность и стратегия вывода

Экономический эффект проекта складывается не из одной метрики, а из нескольких источников ценности сразу. Во-первых, любая более точная рекомендация по условиям снижает число scouting injections и количество циклов «аналитик подумал — попробовал — посмотрел — перепробовал». Во-вторых, если RT и expected runtime предсказываются заранее, лаборатория получает новый уровень планирования очереди приборов и проектов. В-третьих, экспертное знание перестает быть чисто персональным активом сильного аналитика и начинает жить в корпоративной системе. Коммерческие продукты и академические обзоры одинаково подчеркивают, что method development остается time-consuming, resource intensive и дорогим процессом, а ценность автоматизации измеряется не только скоростью, но и экономией материалов, времени и повышением воспроизводимости решений. ²⁷

С точки зрения go-to-market самый сильный путь — **сначала внутренняя эксплуатация в собственной лаборатории, потом продуктивизация наружу**. Это дает сразу три преимущества. Во-первых, у вас есть исторические данные и domain experts для разметки. Во-вторых, можно посчитать реальный internal ROI на собственных проектах, а не продавать гипотезу. В-третьих, появится крайне важный для regulated customers артефакт: prospective validation against human analysts in a real lab. После этого наиболее реалистичная внешняя модель продаж выглядит как hybrid of software + services: аудит и очистка данных заказчика, разворачивание модели в private cloud или on-prem, первоначальное обучение/тонкая настройка на его данных, пакет валидации, обучение сотрудников и ежегодная переоценка модели. С учетом data integrity и compliance требований такой services-led entry выглядит намного правдоподобнее, чем идея «сразу продаем универсальный SaaS по подписке всем подряд». ²⁸

Главный экономический ров проекта — это не просто «мы написали ML-модель», а сочетание четырех вещей: хорошо описанный data model; очищенный архив исторических bioanalytical runs; лабораторно-специфическая валидация; и накопленная библиотека не только успешных, но и неуспешных методических поисков. Публичные ресурсы вроде METLIN SMRT и RepoRT очень полезны для pretraining и архитектурных экспериментов, но production-качество в реальной аналитической среде, скорее всего, будет определяться именно локальной историей конкретной лаборатории. Отсюда и бизнес-идея «мы внедряем ИИ в чужую рутину, дообучая модель на их данных» выглядит сильной: она соответствует фактическому состоянию науки, где переносимость уже возможна, но локальная адаптация все еще критична. ²⁹

Рекомендованная дорожная карта

Первый контур должен быть не про «автономную разработку методики», а про **data foundation**. На этом этапе задача — собрать и нормализовать исторические данные, унифицировать словари веществ, колонок, подвижных фаз, приборов и исходов экспериментов, связать raw chromatograms с метаданными и QC-решениями, а также определить узкий пилотный домен. Если уже здесь выяснится, что большая часть архива существует только в виде разрозненных PDF-отчетов без структурированных условий и без доступа к сырым данным, это не stop signal, но

это радикально меняет продукт: сначала придется делать knowledge layer и recommendation engine, а не «deep model from day one». Такой порядок полностью согласуется и с научной литературой о фрагментированности retention data, и с логикой автоматизированного method development, где качество objective function и качество входных данных определяют потолок автоматизации. ³⁰

Второй контур — forward prediction. Здесь я бы ставил целью не «идеальный метод», а измеримые показатели: median absolute RT error, доля попаданий в допустимое окно RT, ошибка по peak width, качество ранжирования условий, вероятность выполнения system suitability criteria и калиброванная uncertainty. Именно на этом этапе полезно сравнить несколько семейств моделей: descriptor-based baseline, gradient boosting, graph neural networks и transfer-learning подходы. Если в пилотном домене удастся стабильно предсказывать RT и хотя бы часть peak-quality метрик лучше экспертной эвристики, проект уже получает сильное основание для расширения. Если же точность окажется хорошей только на RT, это все равно может быть достаточным для первого коммерческого продукта — планировщика и рекомендательной системы для method scouting. ³¹

Третий контур — inverse design и коммерциализация. Обратную задачу лучше запускать как constrained optimization поверх forward models: пользователь задает RT window, minimum resolution, acceptable tailing/S/N и ограничения по колонкам/буферам/прибору, а система выдает shortlist условий с confidence score и ожидаемым trade-off между качеством и длительностью анализа. Технологически это ближе к уже доказанным Bayesian optimization и closed-loop подходам, чем к «с нуля сгенерированной» методике без опоры на физику и архив. Если такой режим покажет prospective win-rate на реальных проектах лаборатории, решение уже можно выносить начальству как основу для бизнес-плана, а наружу — как AI-copilot platform для bioanalytical method development. В таком виде проект я бы оценил как **реализуемый, экономически оправданный и потенциально сильный как будущий spin-out**, но только при условии, что первая версия будет узкой, данно-центричной и compliance-aware, а не сразу «универсальным ИИ вместо аналитика». ³²

¹ ¹² ²⁷ <https://www.sciencedirect.com/science/article/abs/pii/S0021967323008026>
<https://www.sciencedirect.com/science/article/abs/pii/S0021967323008026>

² ³ ⁷ ⁹ ¹³ <https://www.sciencedirect.com/science/article/abs/pii/S0165993625000755>
<https://www.sciencedirect.com/science/article/abs/pii/S0165993625000755>

⁴ ²³ <https://www.nature.com/articles/s42004-024-01135-0>
<https://www.nature.com/articles/s42004-024-01135-0>

⁵ ¹⁵ ²⁰ Improved workflow for constructing machine learning models: Predicting retention times and peak widths in oligonucleotide separation - ScienceDirect
<https://www.sciencedirect.com/science/article/pii/S0021967325000950>

⁶ ²⁴ ²⁵ <https://www.waters.com/nextgen/us/en/products/informatics-and-software/chromatography-software/empower-software-solutions/empower-method-development-tools.html?srsltid=AfmBOordxrFdIHbDCPBtqDOiFSbudMKg8zIZVM0I7rziZukw7bT4Ph6I>
<https://www.waters.com/nextgen/us/en/products/informatics-and-software/chromatography-software/empower-software-solutions/empower-method-development-tools.html?srsltid=AfmBOordxrFdIHbDCPBtqDOiFSbudMKg8zIZVM0I7rziZukw7bT4Ph6I>

⁸ <https://pubmed.ncbi.nlm.nih.gov/40014655/>
<https://pubmed.ncbi.nlm.nih.gov/40014655/>

- 10 14 22 32 <https://www.sciencedirect.com/science/article/pii/S0003267023000107>
<https://www.sciencedirect.com/science/article/pii/S0003267023000107>
- 11 30 **Transfer learning for small molecule retention predictions - ScienceDirect**
<https://www.sciencedirect.com/science/article/abs/pii/S0021967321002430>
- 16 <https://www.fda.gov/regulatory-information/search-fda-guidance-documents/m10-bioanalytical-method-validation-and-study-sample-analysis>
<https://www.fda.gov/regulatory-information/search-fda-guidance-documents/m10-bioanalytical-method-validation-and-study-sample-analysis>
- 17 19 28 <https://www.ecfr.gov/current/title-21/chapter-I/subchapter-A/part-11>
<https://www.ecfr.gov/current/title-21/chapter-I/subchapter-A/part-11>
- 18 https://www.agilent.com/en/product/software-informatics/analytical-software-suite/chromatography-data-systems/openlab-cds/data-analysis-method-development?srsId=AfmBOor3zMWuyoxu3QqcD41qS-ZI_9vWQ8s11jWVizwqcMomjFZkIp4
https://www.agilent.com/en/product/software-informatics/analytical-software-suite/chromatography-data-systems/openlab-cds/data-analysis-method-development?srsId=AfmBOor3zMWuyoxu3QqcD41qS-ZI_9vWQ8s11jWVizwqcMomjFZkIp4
- 21 31 **Performance and robustness of small molecule retention time prediction with molecular graph neural networks in industrial drug discovery campaigns | Scientific Reports**
<https://www.nature.com/articles/s41598-024-59620-4>
- 26 <https://www.grandviewresearch.com/industry-analysis/high-performance-liquid-chromatography-market-report>
<https://www.grandviewresearch.com/industry-analysis/high-performance-liquid-chromatography-market-report>
- 29 <https://www.nature.com/articles/s41467-019-13680-7>
<https://www.nature.com/articles/s41467-019-13680-7>