

ChromaIntel LC-MS/MS: MVP-дашборд

Размер датасета, качество моделей, пропуски, переносимость между источниками и roadmap

15 052

Строк master

15 052

Строк model matrix


3 945

Соединений


4

Семейств источников

Топ источников по числу строк



Наибольшая доля пропусков




Ключевые выводы

- Цели предсказания: retention time `rt\_min` и временный surrogate `quality\_score`.
- Основной RT-датасет теперь публичный и смешанный: RepoRT + MCMRT + mock/internal шаблоны.
- MCMRT добавляет 30 reversed-phase LC-методов и позволяет проверять перенос на новый источник.
- Quality-модель пока диагностическая: публичные RT-источники почти не содержат реальных peak-quality метрик.


Сравнение моделей

Выбор модели теперь основан на GroupKFold по InChIKey, без утечки соединений между fold'ами.

RT GroupKFold MAE: ниже лучше



RT GroupKFold RMSE: ниже лучше



Модель RT	MAE CV	RMSE CV	R² CV
extra_trees	1.849	3.163	0.909
random_forest	1.983	3.346	0.898
xgboost	2.030	3.320	0.900
hist_gradient_b...	2.072	3.396	0.895
catboost	2.164	3.363	0.897
linear_ridge	3.776	5.681	0.709

Quality surrogate	Val MAE	Test MAE	Test R²
linear_ridge	0.000	0.000	0.850
random_forest	0.000	0.000	0.938
extra_trees	0.000	0.000	0.948
hist_gradient_boo...	0.000	0.000	0.690
xgboost	0.000	0.000	0.908
catboost	0.000	0.000	0.912

Выбрано: RT = extra_trees; quality = random_forest

q90 uncertainty proxy: 4.517 мин

Примечание: quality_score пока проху, не лабораторный acceptance label.

Полная матрица сравнения моделей

Проверенные модели: Ridge, RandomForest, ExtraTrees, HistGradientBoosting, XGBoost, CatBoost.

RT GroupKFold	MAE	RMSE	R2
extra_trees	1.849	3.163	0.909
random_forest	1.983	3.346	0.898
xgboost	2.030	3.320	0.900
hist_gradient_boos...	2.072	3.396	0.895
catboost	2.164	3.363	0.897
linear_ridge	3.776	5.681	0.709

RT final holdout	Val MAE	Test MAE	Test R2
extra_trees	1.917	1.861	0.920
random_forest	2.090	1.989	0.904
xgboost	2.074	1.991	0.910
hist_gradient_boos...	2.056	2.095	0.904
catboost	2.238	2.186	0.903
linear_ridge	3.653	3.891	0.737

Quality GroupKFold	MAE	RMSE	R2
random_forest	0.000	0.001	0.950
catboost	0.000	0.001	0.919
extra_trees	0.000	0.001	0.901
xgboost	0.000	0.001	0.897
linear_ridge	0.000	0.003	0.554
hist_gradient_boos...	0.000	0.005	0.200


Quality final holdout	Val MAE	Test MAE	Test R2
extra_trees	0.000	0.000	0.948
random_forest	0.000	0.000	0.938
catboost	0.000	0.000	0.912
xgboost	0.000	0.000	0.908
linear_ridge	0.000	0.000	0.850
hist_gradient_boos...	0.000	0.000	0.690

Transfer holdout	Модель	N	MAE	RMSE	R2
MCMRT	hist_gradient...	10073	3.585	4.904	0.763
MCMRT	random_forest	10073	3.625	4.858	0.767
MCMRT	xgboost	10073	3.666	5.007	0.753
MCMRT	extra_trees	10073	4.016	5.464	0.705
MCMRT	catboost	10073	4.172	5.852	0.662
MCMRT	linear_ridge	10073	5.335	6.998	0.517
RepoRT	hist_gradient...	4972	5.184	8.075	0.471
RepoRT	catboost	4972	5.187	7.760	0.511
RepoRT	extra_trees	4972	5.254	7.765	0.510
RepoRT	xgboost	4972	5.528	8.445	0.421


Валидация и переносимость

Split: group_shuffle_holdout_with_group_kfold_model_selection | group = inchikey | overlap train/val/test = {'train_validation': 0, 'train_test': 0, 'validation_test': 0}

Holdout MCMRT: train без MCMRT




Holdout RepoRT: train без RepoRT



Источник	Модель	N	MAE	RMSE	R²
MCMRT	hist_gradien...	10073	3.585	4.904	0.763
MCMRT	random_forest	10073	3.625	4.858	0.767
MCMRT	xgboost	10073	3.666	5.007	0.753
MCMRT	extra_trees	10073	4.016	5.464	0.705
MCMRT	catboost	10073	4.172	5.852	0.662
MCMRT	linear_ridge	10073	5.335	6.998	0.517
RepoRT	hist_gradien...	4972	5.184	8.075	0.471
RepoRT	catboost	4972	5.187	7.760	0.511

Наихудшие source-wise ошибки




Как читать эту страницу

Source-family holdout показывает перенос: модель обучается без всего семейства источника и тестируется на нём. Это строже random split и ближе к вопросу: «сработает ли на новом наборе методик?»

Значимость параметров и диагностика ошибок

Permutation importance рассчитан для выбранной RT-модели на holdout-наборе.

Топ-10 факторов RT



Фича	Группа	Imp.	Сигнал
logp	compound_desc...	3.419	positive
gradient_durati...	lc_numeric	3.063	positive
total_runtime_m...	lc_numeric	1.746	positive
column_name	lc_categorical	0.445	positive
heavy_atom_count	compound_desc...	0.280	positive
gradient_slope_...	lc_numeric	0.248	positive
molecular_weight	compound_desc...	0.230	positive
ion_mode	ms_setting	0.188	positive
hbond_donors	compound_desc...	0.161	positive
mobile_phase_a	lc_categorical	0.156	positive

Holdout diagnostics: N=3247 | RT MAE=1.861 мин | RT RMSE=3.173 мин | AD flags=0

Соединение	Источник	Факт RT	Прогноз RT	Ошибка
sophorose	RepoRT:00...	1.640	53.724	52.084
Salicylic acid	RepoRT:00...	81.600	39.720	41.880
Pelargonidin	RepoRT:00...	41.990	81.524	39.534
Clenbuterol	MCMRT:CM ...	22.870	48.984	26.114
Destruxin B	MCMRT:CM ...	57.770	36.709	21.061
Gliotoxin	MCMRT:CM ...	41.680	21.924	19.756
emodin	RepoRT:00...	46.405	28.130	18.275
Gallic acid	RepoRT:00...	16.540	33.757	17.217
Alternariol	MCMRT:CM ...	49.870	33.018	16.852

Roadmap развития

Что делать дальше, чтобы MVP стал лабораторно полезным, а не только публичным benchmark.

0-2 недели: данные лаборатории

- Загрузить исторические BE-style разработки: accepted, failed, low intensity, poor resolution, carryover.
- Стабилизировать словари matrix, ion mode, column family, solvent system, instrument platform.
- Добавить import preview: пропуски, недопустимые диапазоны, дубликаты runs, ошибки SMILES.

2-4 недели: честная оценка качества

- Держать GroupKFold по InChIKey как baseline validation.
- Добавить holdout по method family/column family и отдельную проверку на internal-only split.
- Калибровать conformal intervals по source/matrix/column chemistry.

1-2 месяца: рекомендации методик

- Разложить recommendation score на RT fit, quality, runtime, confidence и AD penalty.
- Ограничить search space утверждёнными колонками, растворителями, pH, flow, temperature и runtime.
- Собирать feedback от химиков и использовать его для active learning.

2-4 месяца: SOTA track

- Сравнить descriptor+GBM с Morgan fingerprints, graph encoders и structure Transformer embeddings.
- Для межметодного переноса добавить retention-order/ranking objective, а не только absolute RT.
- Отдельно обучать/калибровать модели под bioanalytical matrix и instrument platform.

Decision gate: не заявлять production readiness, пока нет внутреннего лабораторного датасета, source/method holdout и критериев acceptance от аналитиков.