

ChromaIntel LC-MS/MS: дашборд MVP

Датасет, модели, переносимость между источниками/методами и дальнейшая дорожная карта

213 941

Master rows

строк после canonical merge

213 941

Model rows

строк в model matrix

202 834

Compounds


уникальных соединений

84


Sources

6 семейств

Крупнейшие источники данных



Поля с наибольшей долей пропусков




Ключевые выводы

- Основная supervised-цель: время удержания `rt\_min`. Quality score пока является прозрачным surrogate, а не лабораторным acceptance label.
- Текущий expanded build объединяет ReTiNA, METLIN SMRT Figshare, MCMRT, RepoRT и mock/internal seed без добавления Kaggle descriptor sidecar как новых RT-таргетов.
- Большие CSV/joblib артефакты локальные и воспроизводимые; в git попадают код, отчеты и правила artifact policy.


Сравнение моделей

Random split не используется как единственное доказательство; главный sanity-check здесь GroupKFold по InChIKey и final grouped holdout.

RT GroupKFold MAE



RT final holdout MAE



RT model	CV MAE	CV RMSE	CV R ²	Spearman
extra_trees	1.850	3.140	0.908	0.940
random_forest	1.940	3.302	0.899	0.933
hist_gradient_boosti...	2.156	3.400	0.893	0.923
linear_ridge	3.602	5.456	0.724	0.818


Quality surrogate	CV MAE	CV RMSE	CV R ²
extra_trees	0.000	0.001	0.966
random_forest	0.000	0.001	0.955
linear_ridge	0.000	0.003	0.759
hist_gradient_boosting	0.000	0.005	0.437

Интерпретация


- Выбранная RT-модель: extra_trees
- Quality surrogate: extra_trees
- q90 residual proxy: 3.505 мин
- CatBoost/XGBoost поддерживаются в full-запуске; quick-mode на expanded matrix оставляет CPU-практичный набор.
- Quality-метрики нельзя трактовать как реальное peak-share качество без внутренних lab labels.

Переносимость: source / method / column holdout

Эти проверки важнее случайного split: они отвечают, переносится ли модель на новые источники, методы и семейства колонок.



Scope	Holdout	Best model	N	MAE	nMAE % runtime
source	MCMRT	random_fore...	10073	2.255	7.006
source	METLIN_SMRT_Fig...	random_fore...	357	2.347	10.203
source	ReTiNA	extra_trees	2439	3.075	14.495
source	RepoRT	extra_trees	4491	4.239	17.447
method	Thermo Hypersil...	extra_trees	1340	0.631	2.935
method	Acclaim RSLC 12...	extra_trees	2010	1.560	5.474
method	ACQUITY PRIMER ...	extra_trees	1340	2.716	5.689
column	unknown	extra_trees	4291	2.396	11.438
column	C18	random_fore...	13064	2.978	9.643




Что это значит

- Если holdout MAE резко хуже grouped holdout, модель запоминает локальные режимы метода/источника и нуждается в method-conditioned features или calibrants.
- Для bioanalytical BE-style применения главный следующий gate: internal time-based или new-method holdout на реальных лабораторных runs.

Значимость параметров и ошибки holdout

Permutation importance показывает, какие признаки реально двигают RT-модель на текущем holdout.



Feature	Group	Importance	Signal
logp	compound_descrip...	2.828	positive
gradient_duration_min	lc_numeric	2.507	positive
total_runtime_min	lc_numeric	1.344	positive
initial_organic_pct	lc_numeric	0.745	positive
column_name	lc_categorical	0.398	positive
gradient_slope_perce...	lc_numeric	0.397	positive
heavy_atom_count	compound_descrip...	0.282	positive
mobile_phase_system	lc_categorical	0.277	positive
molecular_weight	compound_descrip...	0.259	positive
hbond_donors	compound_descrip...	0.199	positive

Holdout: N=42,533 | MAE=1.429 мин | RMSE=2.313 мин

Compound	Source	Actual RT	Pred RT	Error
Chlorogenic acid	RepoRT:0039	41.070	71.435	30.365
ReTiNA:report:63:...	ReTiNA:report	41.070	71.367	30.297
ReTiNA:mcmrt:34:5...	ReTiNA:mcmrt	35.000	65.265	30.265
Tetrandrine	MCMRT:CM 16	35.000	65.181	30.181
Hydrocodone	MCMRT:CM 16	12.090	39.741	27.651
ReTiNA:mcmrt:34:5...	ReTiNA:mcmrt	12.090	39.741	27.651
ReTiNA:mcmrt:34:9...	ReTiNA:mcmrt	22.870	49.189	26.319
Clenbuterol	MCMRT:CM 16	22.870	49.189	26.319
ReTiNA:mcmrt:34:5...	ReTiNA:mcmrt	9.290	33.191	23.901
Codeine	MCMRT:CM 16	9.290	33.191	23.901

Applicability domain

AD flags: 0

Низкий AD support должен понижать confidence и штрафовать inverse recommendation.

Roadmap: от MVP к лабораторной платформе

Следующий рост качества зависит не только от архитектуры, а прежде всего от внутренних peak-quality и assay outcome labels.

1. Данные и lab feedback

- Подключить реальные BE-style historical runs: accepted, failed, low intensity, poor resolution, carryover.
- Разделить labels: measured peak quality, derived surrogate, weak label, unknown.
- Добавить time-based internal holdout и source-quality score.

2. Модели

- Сравнить core vs Morgan/full на expanded matrix.
- Запустить XGBoost/CatBoost full run и dependency-gated graph/SMILES-transformer embeddings.
- Добавить quantile/conformal intervals по source/method/column-family.

3. Inverse recommendation

- Расширить YAML/JSON method templates под доступные колонки и растворители лаборатории.
- Ранжировать по RT fit, quality, runtime, uncertainty, AD penalty, order score и transition support.
- Сохранять каждую рекомендацию в audit trail для последующего active learning.

4. Дашборды и release

- Добавить в Streamlit source/method/column holdout panels и import preview для local-public CSV.
- Smoke-test FastAPI и Streamlit перед release.
- Определить artifact/LFS policy для передачи больших trained bundles.

Decision gate: не заявлять production readiness, пока нет внутреннего validation split, реальных peak-shape labels и проверенной переносимости на новые методы.