

ChromaIntel LC-MS/MS: дашборд MVP

Датасет, модели, переносимость между источниками/методами и дальнейшая дорожная карта

213 941

Master rows

строк после canonical merge

213 941

Model rows

строк в model matrix

202 834

Compounds


уникальных соединений

84


Sources

6 семейств

Крупнейшие источники данных



Поля с наибольшей долей пропусков




Ключевые выводы

- Основная supervised-цель: время удержания `rt\_min`. Quality score пока является прозрачным surrogate, а не лабораторным acceptance label.
- Текущий expanded build объединяет ReTiNA, METLIN SMRT Figshare, MCMRT, RepoRT и mock/internal seed без добавления Kaggle descriptor sidecar как новых RT-таргетов.
- Большие CSV/joblib артефакты локальные и воспроизводимые; в git попадают код, отчеты и правила artifact policy.


Сравнение моделей

Random split не используется как единственное доказательство; главный sanity-check здесь GroupKFold по InChIKey и final grouped holdout.

RT GroupKFold MAE



RT final holdout MAE



RT model	CV MAE	CV RMSE	CV R ²	Spearman
extra_trees	1.639	2.874	0.923	0.949
random_forest	1.756	2.991	0.917	0.944
hist_gradient_boosti...	1.912	3.049	0.914	0.936
linear_ridge	3.503	5.284	0.741	0.831


Quality surrogate	CV MAE	CV RMSE	CV R ²
extra_trees	0.000	0.001	0.946
random_forest	0.000	0.002	0.947
linear_ridge	0.000	0.003	0.759
hist_gradient_boosting	0.000	0.005	0.353

Интерпретация


- Выбранная RT-модель: extra_trees
- Quality surrogate: extra_trees
- q90 residual proxy: 2.882 мин
- CatBoost/XGBoost поддерживаются в full-запуске; quick-mode на expanded matrix оставляет CPU-практичный набор.
- Quality-метрики нельзя трактовать как реальное peak-share качество без внутренних lab labels.

Переносимость: source / method / column holdout

Эти проверки важнее случайного split: они отвечают, переносится ли модель на новые источники, методы и семейства колонок.



Scope	Holdout	Best model	N	MAE	nMAE % runtime
source	MCMRT	random_fore...	10073	2.197	6.825
source	METLIN_SMRT_Fig...	hist_gradie...	357	2.228	9.688
source	ReTiNA	extra_trees	2439	3.081	14.521
source	RepoRT	extra_trees	4491	4.217	17.358
method	Thermo Hypersil...	extra_trees	1340	0.641	2.980
method	Acclaim RSLC 12...	hist_gradie...	2010	1.475	5.174
method	ACQUITY PRIMER ...	hist_gradie...	1340	2.480	5.193
column	unknown	random_fore...	4291	2.424	11.573
column	C18	extra_trees	13064	2.879	9.322




Что это значит

- Если holdout MAE резко хуже grouped holdout, модель запоминает локальные режимы метода/источника и нуждается в method-conditioned features или calibrants.
- Для bioanalytical BE-style применения главный следующий gate: internal time-based или new-method holdout на реальных лабораторных runs.

Значимость параметров и ошибки holdout

Permutation importance показывает, какие признаки реально двигают RT-модель на текущем holdout.



Feature	Group	Importance	Signal
gradient_duration_min	lc_numeric	2.848	positive
total_runtime_min	lc_numeric	1.353	positive
estimated_logd_ph3	compound_descrip...	0.845	positive
estimated_logd_ph7	compound_descrip...	0.777	positive
initial_organic_pct	lc_numeric	0.741	positive
logp	compound_descrip...	0.638	positive
column_name	lc_categorical	0.395	positive
gradient_slope_perce...	lc_numeric	0.316	positive
mobile_phase_system	lc_categorical	0.254	positive
final_organic_pct	lc_numeric	0.160	positive

Holdout: N=42,533 | MAE=1.187 мин | RMSE=1.994 мин

Compound	Source	Actual RT	Pred RT	Error
ReTiNA:mcmrt:34:5...	ReTiNA:mcmrt	35.000	59.365	24.365
Tetrandrine	MCMRT:CM 16	35.000	59.365	24.365
ReTiNA:mcmrt:34:5...	ReTiNA:mcmrt	12.090	36.132	24.042
Hydrocodone	MCMRT:CM 16	12.090	36.132	24.042
ReTiNA:report:63:...	ReTiNA:report	92.700	69.394	23.306
ReTiNA:report:63:...	ReTiNA:report	92.700	69.394	23.306
Ethyl Caffeaate	RepoRT:0039	92.700	69.594	23.106
Chlorogenic acid	RepoRT:0039	41.070	62.899	21.829
ReTiNA:mcmrt:34:4...	ReTiNA:mcmrt	39.600	18.089	21.511
Hexazinone	MCMRT:CM 16	39.600	18.089	21.511

Applicability domain


AD flags: 0

Низкий AD support должен понижать confidence и штрафовать inverse recommendation.

Peak targets и ML-модель обратной задачи


Эта страница отделяет измеренные peak labels от proxy targets и показывает baseline для inverse ranking.

Target coverage



Target	Coverage	Label	Readiness
rt_min	1.000	measured	trainable
quality_score	1.000	derived_proxy	trainable
asymmetry	0.000	unavailable	unavailable
tailing_factor	0.000	unavailable	unavailable
peak_width_base_min	0.000	unavailable	unavailable
peak_width_half_heigh...	0.000	unavailable	unavailable
resolution	0.000	unavailable	unavailable
sn_ratio	0.000	unavailable	unavailable
peak_area	0.000	unavailable	unavailable
peak_height	0.000	unavailable	unavailable
low_intensity_risk	0.000	derived_proxy	proxy_only

Inverse PR-AUC



Model	ROC-AUC	PR-AUC	Brier	Top-3
logistic_regression	1.000	1.000	0.000	1.000
random_forest	1.000	1.000	0.000	1.000
extra_trees	1.000	1.000	0.000	1.000
hist_gradient_boosti...	1.000	1.000	0.000	1.000
xgboost	1.000	1.000	0.000	1.000
catboost	1.000	1.000	0.000	1.000

Inverse labels сейчас synthetic_proxy: они проверяют ранжирование candidate methods, но не заменяют реальные accepted/failed lab outcomes.

Roadmap: от MVP к лабораторной платформе

Следующий рост качества зависит не только от архитектуры, а прежде всего от внутренних peak-quality и assay outcome labels.

1. Данные и lab feedback

- Подключить реальные BE-style historical runs: accepted, failed, low intensity, poor resolution, carryover.
- Разделить labels: measured peak quality, derived surrogate, weak label, unknown.
- Добавить time-based internal holdout и source-quality score.

2. Модели

- Сравнить core vs Morgan/full на expanded matrix.
- Запустить XGBoost/CatBoost full run и dependency-gated graph/SMILES-transformer embeddings.
- Добавить quantile/conformal intervals по source/method/column-family.

3. Inverse recommendation

- Расширить YAML/JSON method templates под доступные колонки и растворители лаборатории.
- Ранжировать по RT fit, quality, runtime, uncertainty, AD penalty, order score и transition support.
- Сохранять каждую рекомендацию в audit trail для последующего active learning.

4. Дашборды и release

- Добавить в Streamlit source/method/column holdout panels и import preview для local-public CSV.
- Smoke-test FastAPI и Streamlit перед release.
- Определить artifact/LFS policy для передачи больших trained bundles.

Decision gate: не заявлять production readiness, пока нет внутреннего validation split, реальных peak-shape labels и проверенной переносимости на новые методы.